

YAPAY ZEKA VE DERİN ÖĞRENME ARAŞTIRMA VE STAJ RAPORU 1

Hazırlayan: Reyhan Türk

1. YAPAY SİNİR AĞLARI (ARTIFICIAL NEURAL NETWORKS - ANN)

Yapay Sinir Ağları (Artificial Neural Networks - ANN), insan beyninin biyolojik sinir ağı yapısını matematiksel olarak modelleyen ve bu sayede verilerden öğrenme gerçekleştiren bilgi işlem sistemleridir. Temel yapı taşları nöronlar (neurons), ağırlıklar (weights) ve sapma (bias) değerleridir.

1.1 Temel Kavramlar

- **Nöronlar (Neurons):** Girdileri alan, bunları belirli ağırlıklarla (weights) çarparak toplayan ve elde edilen sonucu bir eşik değeri (threshold) doğrultusunda aktivasyon fonksiyonundan (activation function) geçirerek karar üreten temel işlem birimleridir.
- **Ağırlıklar (Weights):** Bir girdinin (input) ağırlığının nihai kararı veya çıktısı (output) üzerinde ne kadar etkisi olduğunu gösteren, eğitim sürecinde güncellenen katsayılar.
- **Sapma (Biases):** Girdiler (inputs) tamamen sıfır veya çok zayıf olsa bile nöronun tetiklenmesine olanak tanıyan, matematiksel doğrunun kayma miktarını belirleyen sabit değerlerdir.

1.2 Yapay Sinir Ağı Türleri (Types of Neural Networks)

1. **İleri Beslemeli Sinir Ağları (Feed Forward Neural Networks - FNN):** Bilgi akışının tek yönde, giriş katmanından (input layer) çıkış katmanına (output layer) doğru kesintisiz ilerlediği en temel ağ yapısıdır. Geri bildirim döngüsü (feedback loop) bulunmaz.
2. **Evrişimsel Sinir Ağları (Convolutional Neural Networks - CNN):** Özellikle görsel verilerdeki kenarlar, dokular ve desenler (patterns) gibi özellikleri yakalamak için evrişimli (convolutional) katmanlar kullanan özel mimarilerdir.
3. **Tek Katmanlı Perseptron (Single-layer Perceptron):** Sadece giriş katmanı (input layer) ve çıkış katmanından (output layer) oluşan en basit sinir ağıdır. Girdileri alır, ağırlıklarla (weights) çarpar, toplar ve aktivasyon fonksiyonundan (activation function) geçirerek doğrusal ayrıştırılabilir problemlerde sonuca ulaşır.
4. **Çok Katmanlı Perseptron (Multilayer Perceptron - MLP):** Bir giriş katmanı (input layer), bir ya da birden fazla gizli (hidden) katman ve bir çıkış katmanından (output layer) oluşan doğrusal olmayan karmaşık ilişkileri öğrenebilen ağ yapısıdır.
5. **Tekrarlayan Sinir Ağları (Recurrent Neural Network - RNN):** Kendi üzerinde geri bildirim döngüleri (loops) barındırarak ardışık ve zamana bağlı verileri (metin, zaman serileri) işleyebilen, geçmiş bilgiyi hafızasında tutan ağ türüdür.
6. **Uzun Kısa Vadeli Bellek (Long Short Term Memory - LSTM):** RNN'lerin uzun vadeli bağımlılıkları yönetirken yaşadığı kaybolan gradyanlar (vanishing gradients) sorununu çözmek amacıyla geliştirilmiş, bellek hücreleri (cell state) ve kapı (gate) mekanizmalarına sahip özel bir RNN türüdür.

1.3 Sinir Ağlarının Çalışma Mekanizması (Working of Neural Networks)

Bir yapay sinir ağının eğitimi ve çalışması temel olarak 3 aşamadan oluşur:

Aşama 1: İleri Yayılım (Forward Propagation)

Veri, giriş katmanından (input layer) başlayarak gizli katmanlar (hidden layers) üzerinden akar ve çıkış katmanına (output layer) ulaşarak bir tahmin değeri (predicted value) üretilir. Bu evrede her nöronda iki temel işlem gerçekleşir:

- **Lineer Dönüşüm (Linear Transformation):** Bir katmandaki her nöron, bağlantılı olduğu bir önceki katmandan gelen girdileri ilgili ağırlıklarla (weights) çarpar, toplar ve üzerine sapma (bias) değerini ekler. Formülü:

$$Z = (w_1 * x_1 + w_2 * x_2 + \dots + w_n * x_n) + b \implies Z = \sum(w_i * x_i) + b$$

- **Aktivasyon Fonksiyonu (Activation Function):** Bulunan doğrusal Z değeri bir aktivasyon fonksiyonuna (ReLU, Sigmoid, Tanh) sokulur. Bu fonksiyon, sisteme doğrusal olmayan (non-linear) bir özellik katarak ağın çok karmaşık problemleri çözebilmesini sağlar.

Aşama 2: Geri Yayılım (Backpropagation)

İleri yayılımdan (forward propagation) sonra ağ, gerçek çıktı (y) ile tahmin edilen çıktı (y^) arasındaki farkı ölçen bir kayıp fonksiyonu (Loss Function) kullanarak performansı değerlendirir. Eğitimin amacı bu kaybı en aza indirmektir. Bu evre 3 adımdan oluşur:

1. **Kayıp Hesaplama (Loss Calculation):** Tahmin ile gerçek değer arasındaki hata payı (kayıp miktarı) matematiksel olarak ölçülür.

2. **Gradyan Hesaplama (Gradient Calculation):** Türevdeki Chain Rule kullanılarak, ağıdaki her bir ağırlık (weight) ve sapmanın (bias) bu toplam hataya ne kadar katkıda bulunduğu (gradyanı) geriye doğru hesaplanır.

3. **Ağırlık Güncelleme (Weight Update):** Gradyanlar hesaplandıktan sonra bir optimizasyon algoritması (Optimizer - SGD, Adam vb.) kullanılarak ağırlıklar (weights) ve sapmalar (biases) güncellenir. Hatayı en aza indirmek için ağırlıklar gradyanın tersi yönünde ayarlanır.

Aşama 3: İterasyon (Iteration)

İleri yayılım (forward propagation), kayıp hesaplama (loss calculation), geri yayılım (backpropagation) ve ağırlık güncelleme (weight update) işlemleri veri kümesi üzerinde birçok kez (epochs/iterations) tekrarlanır. Her iterasyonda hata payı düşer ve tahminlerin doğruluk oranı maksimuma ulaşır.

1.4 Aşırı Öğrenme (Overfitting)

Aşırı Öğrenme (Overfitting): Modelin eğitim verisini (training data), verideki rastgele gürültüleri ve istisnaları dahi kapsayacak şekilde çok fazla öğrenmesi/ezberlemesi durumudur. Bu durumda model eğitim veri setinde mükemmel performans gösterirken, ilk defa karşılaştığı yeni test verilerinde (test data) doğru tahmin üretemez. Çözüm olarak

düzenleştirme (regularization), seyreltme (dropout) veya veri artırma (data augmentation) teknikleri kullanılır.

- **Düzenleştirme (Regularization):** Lasso regresyonu katsayının mutlak değerini ceza olarak verilmesidir. Bu ceza bazı katsayıları 0.1'e indirerek yalnızca önemli özelliklerin seçilmesini sağlar. Ridge regresyonu katsayının karesinin ceza olarak eklenmesidir.

- **Seyreltme (Dropout):** Eş adaptasyonu bir katmandaki birden fazla nöronun giriş verilerinden aynı veya çok benzer gizli özellikleri çıkarması anlamına gelir. Ancak bu 2 soruna yol açar: aynı çıktı hesaplanırken kaynak israfı yapılır, eğer bu veriler eğitim kümesine aitse model overfitting yapıyor olabilir. Bunu engellemek için dropout yöntemiyle her eğitim adımında bir katmanın nöronlarının belirli bir bölümü rastgele kapatılarak nöron değerleri sıfırlanır. Sıfırlanacak değerlerin oranı geri kalan nöronların değerleriyle çarpılır böylece nöron değerlerinin toplamı aynı kalır ve overfitting engellenir.

- **Veri Artırma (Data Augmentation):** Mevcut bir veri kümesindeki örnekleri temel alarak, çeşitli teknikler (görsel veriler için döndürme, kırpma, ölçekleme, renk değişimi, gürültü ekleme vb.) vasıtasıyla sentetik ancak gerçekçi yeni veri örnekleri oluşturma sürecidir.

2. DENETİMLİ ÖĞRENME (SUPERVISED LEARNING)

Algoritmaları eğitmek için etiketlenmiş (labeled) veri kümelerini kullanan bir makine öğrenmesi biçimidir. Giriş verilerinin ve bunlara karşılık gelen doğru çıkışların net ve tutarlı bir şekilde tanımlandığı senaryolarda tercih edilir. Algoritma, girdi (input) ile çıktı (output) arasındaki ilişkileri öğrenebilmek için en doğru matematiksel formülü/fonksiyonu bulmaya çalışır.

2.1 Sınıflandırma (Classification)

Girdi verilerini önceden tanımlanmış kategorik veya ayrık çıktılara (Kedi, Köpek vb.) dönüştürme işlemidir. Sık kullanılan 6 temel sınıflandırma yöntemi şunlardır:

Sınıflandırma Algoritması	Çalışma Prensibi ve Mantığı
1. Lojistik Regresyon (Logistic Regression)	Bir olayın gerçekleşme olasılığını hesaplar. Çıktı 0 ile 1 arasındadır. Elde edilen yüzdelik değere göre eşik geçildiğinde iki değerden birine (0 veya 1) karar verilir.
2. Doğrusal Sınıflandırıcılar (Linear Classifiers)	İki farklı veri grubunu doğrusal bir sınır (çizgi veya hiper-düzlem / hyper-plane) çizerek birbirinden net bir şekilde ayırmayı hedefler.
3. Destek Vektör Makineleri (Support Vector Machines - SVM)	İki grubu birbirinden ayırırken, her iki grubun sınır elemanlarına da en uzak ve en güvenli mesafedeki çizgiyi (Maksimum Marj - Maximum Margin) bulmaya çalışır.

	Çizgiye en yakın olan kritik veri noktalarına 'Destek Vektörleri' (Support Vectors) denir.
4. Karar Ağacı (Decision Tree)	En tepedeki kök düğümünden (root node) başlar. Verinin özelliklerine göre cevabı evet/hayır olan sorular sorarak dallara ayrılır ve yapraklarda (leaves) nihai sonuca ulaşır.
5. Rastgele Orman (Random Forest)	Verilerden rastgele örnekler seçerek yüzlerce farklı karar ağacı oluşturan bir Topluluk Öğrenmesi (Ensemble Learning) yöntemidir. Tahmin sırasında her ağaç kendi sonucunu üretir ve en çok oy alan sonuç nihai karar olur.
6. K-En Yakın Komşu (k-Nearest Neighbors - KNN)	Sınıfı bilinmeyen yeni bir veri geldiğinde, onun en yakınındaki 'K' tane komşusuna bakar. Bu k tane komşu veri içinde en yoğun bulunan sınıf hangisiyse, yeni veriyi de o sınıfa dahil eder.

2.2 Regresyon (Regression)

Regresyon (Regression): Bağımlı (dependent) ve bağımsız (independent) değişkenler arasındaki sürekli ve sayısal ilişkiyi anlamak, geleceğe yönelik sayısal tahminler yapmak için kullanılır. Algoritmaya etiketlenmiş geçmiş veri kümeleri yüklenir, aralarındaki matematiksel formül çözülür ve yeni bir problem geldiğinde buna uygun sayısal tahminler üretilir.

3. DENETİMSİZ ÖĞRENME (UNSUPERVISED LEARNING)

Modelin etiketlenmemiş (unlabeled), hedef çıktısı önceden belirtilmemiş ham veri kümesini kendi başına keşfederek verinin içindeki gizli yapıları, ilişkileri ve kalıpları ortaya çıkarmaya çalıştığı öğrenme paradigmalardan biridir. Süreç şu şekilde ilerler:

- **Ham Veri Analizi (Raw Data Analysis):** Denetimsiz öğrenme algoritmaları (unsupervised learning algorithms) metin gibi çok büyük yapılandırılmamış veri hacimlerini keşfederek gizli kalıpları ve eğilimleri (patterns and trends) bulabilir.
- **Gruplandırma (Grouping):** Veri bölümlendirilmesi (data segmentation) için denetimsiz öğrenme, veri noktalarının özelliklerini inceleyerek ortak noktaları ve kalıpları belirleyebilir ve gruplar oluşturabilir.
- **İlişkiler (Relationships):** Veri noktalarının nasıl bağlantılı olduğunu belirlemek için ağırlığı, mesafeyi ve ilişkilerin kalitesini inceleyebilir. Bu sayede şüpheli kayıtların ikili işaretlemesinin (manuel etiketlemenin) getireceği maliyet ve hataların önüne geçilir.

Algoritma yüksek performansla ulaşılan kadar deneme-yanılma (trial-and-error) yöntemiyle eğitilir. Sonuçlar her seferinde bir uzman eğitici (expert human-in-the-loop) tarafından kontrol edilerek parametreler ayarlanır ve model güçlendirilir.

3.1 Kümeleme (Clustering) Yöntemleri

Kümeleme (Clustering): Etiketlenmemiş verileri kendi aralarındaki benzerliklerine veya farklılıklarına göre gruplara ayıran bir veri madenciliği (data mining) tekniğidir. Temel olarak 3 ana kümeleme türü öne çıkar:

- 1. Ayrıcalıklı ve Örtüşen Kümeleme (Exclusive and Overlapping Clustering):**
Ayrıcalıklı (exclusive) modelde bir veri noktası yalnızca tek bir kümede bulunabilir (Örn: K-Means). Örtüşen (overlapping) modelde ise bir veri noktası farklı üyelik dereceleriyle birden fazla kümede yer alabilir.
- 2. Hiyerarşik Kümeleme (Hierarchical Clustering):** Veri kümeleri başlangıçta ayrı gruplar halinde izole edilir ve tek bir büyük küme elde edilene kadar benzerlik temelinde yinelemeli olarak birleştirilir.
- 3. Olasılıksal Kümeleme (Probabilistic Clustering) & GMM:** Klasik kümeleme yöntemlerinin aksine, verileri "kesin olarak A kümesindedir" diye ayırmak yerine, "%80 ihtimalle A, %20 ihtimalle B kümesindedir" şeklinde esnek bir yaklaşım sunar.

3.2 Birliktelik Kuralları ve Boyut İndirgeme

- **Birliktelik Kuralı (Association Rule):** Belirli bir veri kümesindeki değişkenler arasındaki ilişkileri bulmak için kullanılan kural tabanlı bir yöntemdir. Örneğin bir müşterinin tüketim alışkanlıklarını anlamak.

- *Apriori Algoritmaları (Apriori Algorithms):* Sık kullanılan ürün kelimelerini veya ürün koleksiyonlarını belirlemek ve ürün tüketimi göz önüne alındığında başka bir ürünün tüketilme olasılığını tespit etmek için işlemsel veri kümelerinde (transactional datasets) kullanılır.

- **Boyut İndirgeme (Dimensionality Reduction):** Bir veri kümesindeki özellik veya boyut sayısı (number of features/dimensions) çok olduğunda, anlamlı bilgiyi kaybetmeden boyut sayısını azaltma işlemidir.

4. YARI DENETİMLİ VE KENDİ KENDİNE DENETİMLİ ÖĞRENME

4.1 Yarı Denetimli Öğrenme (Semi-Supervised Learning)

Hem etiketli (labeled) hem etiketlenmemiş (unlabeled) veri kümesi içerir. İlk olarak algoritma denetimli olduğu gibi etiketli veri setiyle eğitilir, sonra etiketsiz veri kümesiyle eğitilerek ilerler. Eğitim sırasında bir kayıp fonksiyonu (loss function) modelin belirli bir girdi için tahminleriyle gerçek değer arasındaki farkı (kayıp) ölçer, modeller kayıpları en aza indirmek için model ağırlıklarını güncelleyen gradyan inişini (gradient descent) kullanırlar. İki önemli alt başlığı vardır:

- **Kendi Kendine Eğitim (Self-Training):** Etiketli veri kümesi kullanılarak algoritma eğitilir, sonraki eğitim etiketlenmemiş veri kümesi için yüksek güvenilirlik sağlayan sahte etiketler (pseudo-labels) oluşturur. Böylece tüm kayıtlar etiketlenir. Daha sonra sistem orijinal veri

kümesi üzerinde eğitim yapar, bu da orijinal etiketli veri kümesine kıyasla daha büyük veri hacimleri üzerinde eğitim yapılmasını sağlar.

- **Birlikte Eğitim (Co-Training):** Her grup ayrı bir algoritma eğitir, ardından her bir sonuçta ortaya çıkan model için sahte etiketler sınıflandırmak üzere etiketlenmemiş bir veri kümesi üzerinde tahminler yapar. Bir sınıflandırıcı tarafından oluşturulan her sahte etiket bir olasılık puanıyla birlikte gelir ve daha yüksek olasılık puanına sahip etiket daha sonra diğer eğitim veri kümesine eklenir.

4.2 Kendi Kendine Denetimli Öğrenme (Self-Supervised Learning)

Dışarıdan insan eliyle verilmiş bir etikete ihtiyaç duymadan, verinin kendi yapısını kullanarak öğrenme gerçekleştiren yaklaşımdır. Etiketlenmemiş ham verinin bir kısmını gizleyerek geri kalan kısmından gizlenen bölümü tahmin etmeye çalışır. Böylece veri, kendi kendisi için bir hedef (etiket) işlevi görür.

Kendi kendine denetimli öğrenme süreçleri iki temel görev türüne dayanır:

1. **Ön Hazırlık Görevleri (Pretext Tasks):** Modelin verinin temel özelliklerini öğrenmesi için tasarlanan yapay görevlerdir. Eksik pikseller kelimeler tamamlanmaya çalışılır.
2. **Alt Görevler (Downstream Tasks):** Pretext aşamasında öğrenilen özelliklerin asıl hedef probleme aktarılmasıdır.

Önceden eğitilmiş bir modelin yeni bir görevde yeniden kullanılmasına Transfer Learning denir.

SSL ile eğitilen modeller şu teknikleri kullanabilir:

- **Self Predictive Learning**
Üretken modellerdir. Girdinin bilmediğimiz bir kısmı varmış gibi davranır ve onu tahmin eder.
 - I. **Otoenkoderler**
Girdi verilerini sıkıştırıp orijinal veriyi yeniden oluşturmak üzere eğitilmiş bir sinir ağıdır. Gürültüleri kaldırır.
 - II. **Otoregresyon**
Gelecekteki davranışı tahmin edebilmek için geçmiş davranışları kullanır. GPT, Claude,...
 - III. **Maskleme**
Veri örneğinin belirli bir kısmını maskeler, eksik bilgileri tahmin etmek ve yeniden oluşturmakla görevlidir.
- **Contrastive Learning**
Modellere birden fazla veri örneği sunar ve bu örnekler arasındaki ilişkiyi karşılaştırma yoluyla tahmin edilmesini ister. Veri arttırma yolu kullanılır.

5. DERİN ÖĞRENME UYGULAMALARI

5.1 Görüntü Tanıma (Image Recognition)

NORMALIZATION: Görüntüleri analize hazırlarken piksel değerlerinin 0 -1 veya -1 – 1 arasında standart bir aralığa getirilmesidir. Görüntüler yeniden boyutlandırılır , Gauss filtreleme yöntemleri kullanılabilir.

FEATURE EXTRACTION:En önemli bilgiyi sağlayan özelliklerin seçilmesidir.

CODING:Görüntü algılanmadığından mühendisler özellikleri ve değerleri sayısal vektörlere dönüştürür.

Görüntü Tanımadaki Derin Öğrenme (Deep Learning For Image Recognition)

Derin öğrenme modelleri CNN kullanarak görüntüyü doğrudan görüntüden öğrenebilir. CNN'ler verilerin yapısal doğasını analiz eden ve öğrenen evrimsel katmanlara sahip derin öğrenme mimarileridir.

- **Giriş Katmanı (Input Layer):**Görüntünün ham piksel değerlerini sayısal yoğunluk ızgarası olarak işleyerek desen çıkarımı için diğer katmanlara iletir.
- **Evrşim (Convolution):**Resim üzerinde bir filtre gezdirir. Bu filtre resimdeki çizgileri ve köşeleri yakalar.
- **Havuzlama (Pooling):**Resmin boyutunu küçültür ve geriye önemli özellikleri bırakır.
- **Düzleştirme (Flattening):**Bulunan nesneler düz bir vektör haline getirilir, çıkış katmanına gönderilir..Bir doğruluk oranı ve nesne bulunur.

5.2 Nesne Tespiti (Object Detection)

Nesne Tespiti (Object Detection): Görüntü üzerindeki nesnelerin sınıflarını ve konumlarını belirleme işlemidir.

Object Localization:Görüntüdeki belirli bir nesnenin konumunu bounding boxla (sınırlayıcı kutu) belirlenmesidir.

Görüntü İşleme (Image Processing): Bilgisayar görüşünde görüntüler 2 boyutla koordinatta temsil edilen sürekli fonksiyonlardır.Görüntüler sayısallaştırıldığında 2 işlemden geçerler; Sampling(örnekleme) ve Quantization(niceleme). Örnekleme görüntünün üzerine ızgaralar çekilerek her karenin 1 piksel olduğunu söyler, çözünürlüğü artırır. Niceleme piksellerdeki rengi bilgisayarın anlayacağı bir sayıya yuvarlama işlemidir.

Model Mimarisi (Model Architecture)

1)Backbone (Omurga):Resimdeki ham pikselleri alır, temel görsel özelliklerini yakalar. Resminde farklı çözünürlüklerinde Feature Maps üretir.Örneğin büyük haritada küçük detayları, küçük haritada büyük yapıları yakalar.

2)Neck (Boyun):Omurganın farklı katmanlarından gelen özellik haritalarını harmanlar.

3)Head (Baş):Son karar verilir. Ekrana bounding boxes çizilir ve etiketleri yazar.Burada 2 farklı nesne yakalama yöntemi vardır:

- a) **Two Stage Detectors:** İlk önce nesne olma olasılığı yüksek bölgeler kutu içine alınır sonra detaylıca incelenir. Konumlandırma doğruluğu yüksek ama yavaştır.
- b) **Single Stage Detectors:** SSD kullanılarak özellik haritalarından doğrudan sınırlayıcı kutuları ve sınıf olasılıkları tahmin edilebilir. YOLO ile görüntü ızgaraya bölünür ve tek bir değerlendirilmede tahmin yapılır.

5.3 Görüntü Segmentasyonu (Image Segmentation)

Görüntü Segmentasyonu (Image Segmentation): Pikselleri sınıflara ait olacak şekilde etiketleyerek görsel verileri işler. Things ağaç, insan gibi örnekleri spesifik olan nesnelerdir. Stuff gökyüzü, su gibi biçimsiz örneklerdir.

Ardından segmentasyon görevleri şu 3 madde halinde listelenir:

1. *Anlamsal Segmentasyon (Semantic Segmentation):* Pikselleri stuff olarak ele alır, insan topluluğuna insan der.
2. *Örnek Segmentasyonu (Instance Segmentation):* Her ayrı nesnenin örneğinin şeklini ayrı belirler.
3. *Panoptik Segmentasyon (Panoptic Segmentation):* Her nesne örneğini birbirinden ayırır. 3 insan varsa her birine tek tek insan der.

Yaygın Görüntü İşleme Teknikleri:

1. **Region Based Segmentation:** Benzer özelliklere sahip komşu pikselleri bir araya getirir.
2. **Kenar Algılama (Edge Detection):** Parlaklık veya kontrasttaki süreksizlikleri tespit ederek kenarları bulur.
3. **Watersheds:** Görüntüleri gri tonlamaya dönüştürür ve her pikselin yüksekliğinin parlaklığına göre belirlendiği bir topografik haritaya dönüştürerek bölgeler, sınırlar ve nesneler tespit edilir.
4. **Histograms:** Görüntüdeki belirli piksel değerlerinin sıklığını gösteren histogramlar genellikle eşik değerlerinin tanımlamak için kullanılır.
5. **Eşikleme (Thresholding):** Piksel değerinin belirli bir eşik değerinin altında veya üstünde olmasına bağlı olarak pikselleri sınıflandırarak ikili görüntüler oluşturur. Otsu's Methodu sınıf içi varyasyonu en aza indiren eşik değerini otomatik ayarlayıp görüntüyü siyah-beyaz yapan bir yöntemdir.

Yaygın Derin Öğrenme Modelleri:

1)FCN(TAMAMEN EVRİŞİMSSEL AĞLAR): Görüntü bölütleme (segmentation) işlemini uçtan uca gerçekleştiren ilk popüler modeldir.

2)U-NETLER: Özellikle tıbbi görüntüleme (MR, Tomografi analizi vb.) için geliştirilmiş bir mimaridir. İki ana kısımdan oluşur: Görüntüyü küçülterek özellikleri anlayan sol taraf (Encoder) ve görüntüyü tekrar orijinal boyutuna getirerek pikselleri konumlandıran sağ taraf (Decoder). "Skip connections" (atlama bağlantıları) sayesinde detaylar kaybolmadan çok az veriyle bile mükemmel bölütleme yapar.

3)DeepLab: Standart pikseller yerine aralıklı piksellere bakan Atrous Convolution (Genişletilmiş Evrişim) tekniğini kullanır. Bu sayede hesaplama maliyetini artırmadan çok daha geniş bir alanı (büyük resmi) görebilir ve nesnelerin kenarlarını kusursuz çizer.

4)Mask R-CNN'LER: Görseldeki nesnelerin hem yerini tespit eden (Object Detection) hem de sınırlarını piksel piksel çizen (Instance Segmentation) modelidir.

5)TRANSFORMERS: Öz-Dikkat (Self-Attention) mekanizmasını kullanır. Bu mekanizma sayesinde veri içerisindeki uzun vadeli ve global ilişkileri aynı anda (paralel olarak) işleyebilir. Çok büyük verilerde rakipsiz performans gösterir.

6. EVRİŞİMSEL SİNİR AĞLARI (CONVOLUTIONAL NEURAL NETWORKS - CNN)

Evrışimsel Sinir Ağları (Convolutional Neural Networks - CNN), özellikle görsel verileri işlemek ve bu veriler üzerinden otomatik öznitelik çıkarımı yapmak amacıyla kullanılan derin öğrenme mimarileridir.

6.1 CNN Nasıl Çalışır?

Bir CNN modelinin nasıl çalıştığı temel olarak 3 katman üzerinden açıklanır:

1. Evrişim Katmanı (Convolutional Layer) *Filtre sayısı arttıkça derinlik artar, Stride filtrenin her işlemde sonra kaç piksel kaydırılacağıdır, Padding resmin kenarlarından küçülmemesi için etrafının 0'la doldurulmasıdır. Conv2D en yaygın kullanılan evrişim katmanıdır.*

2. Havuzlama Katmanı (Pooling Layer) *Özellik haritalarının boyutunu küçülterek parameter sayısını azaltır, her bölgesine filtre uygulayarak overfittingi engeller.*

3. Tam Bağlantılı Katman (Fully Connected Layer) *Çıkış katmanındaki her düğüm önceki katmandaki bir düğüme doğrudan bağlıdır. Girdileri sınıflandırmak için 0 ile 1 arasında bir olasılık üretir, ağırlıklı toplam ve sapma hesaplanır. Bu değerler aktivasyon fonksiyonundan geçirilir ve sınıflandırma yapılmış olur.*

Her evrişim işleminden sonra özellik haritasına ReLU (Doğrusal Düzeltme Birimi) dönüşümü uygulanarak modele doğrusal olmayan bir yapı kazandırılır. ReLU aktivasyon fonksiyonu matristeki negative değerleri 0 yapar. Bu sayede görüntüdeki karmaşık ve kıvrımlı yapılar öğrenilebilir.

6.2 CNN Modelinin Eğitimi (Training a CNN)

- Veri Ön İşleme (Data Preprocessing) ve Normalizasyon:** Görünüler aynı format ve boyuta getirilir.
- Kayıp Fonksiyonu (Loss Function):** CNN'in performansını gösterir. (tahmin-gerçek)
- Optimizer:** Loss değerini sıfırlamak için CNN'in ağırlıklarını günceller.
- Backpropagation(Geri Yayılım):** CNN'in ağırlıklarına göre kayıp fonksiyonun ağırlıklarını hesaplar.