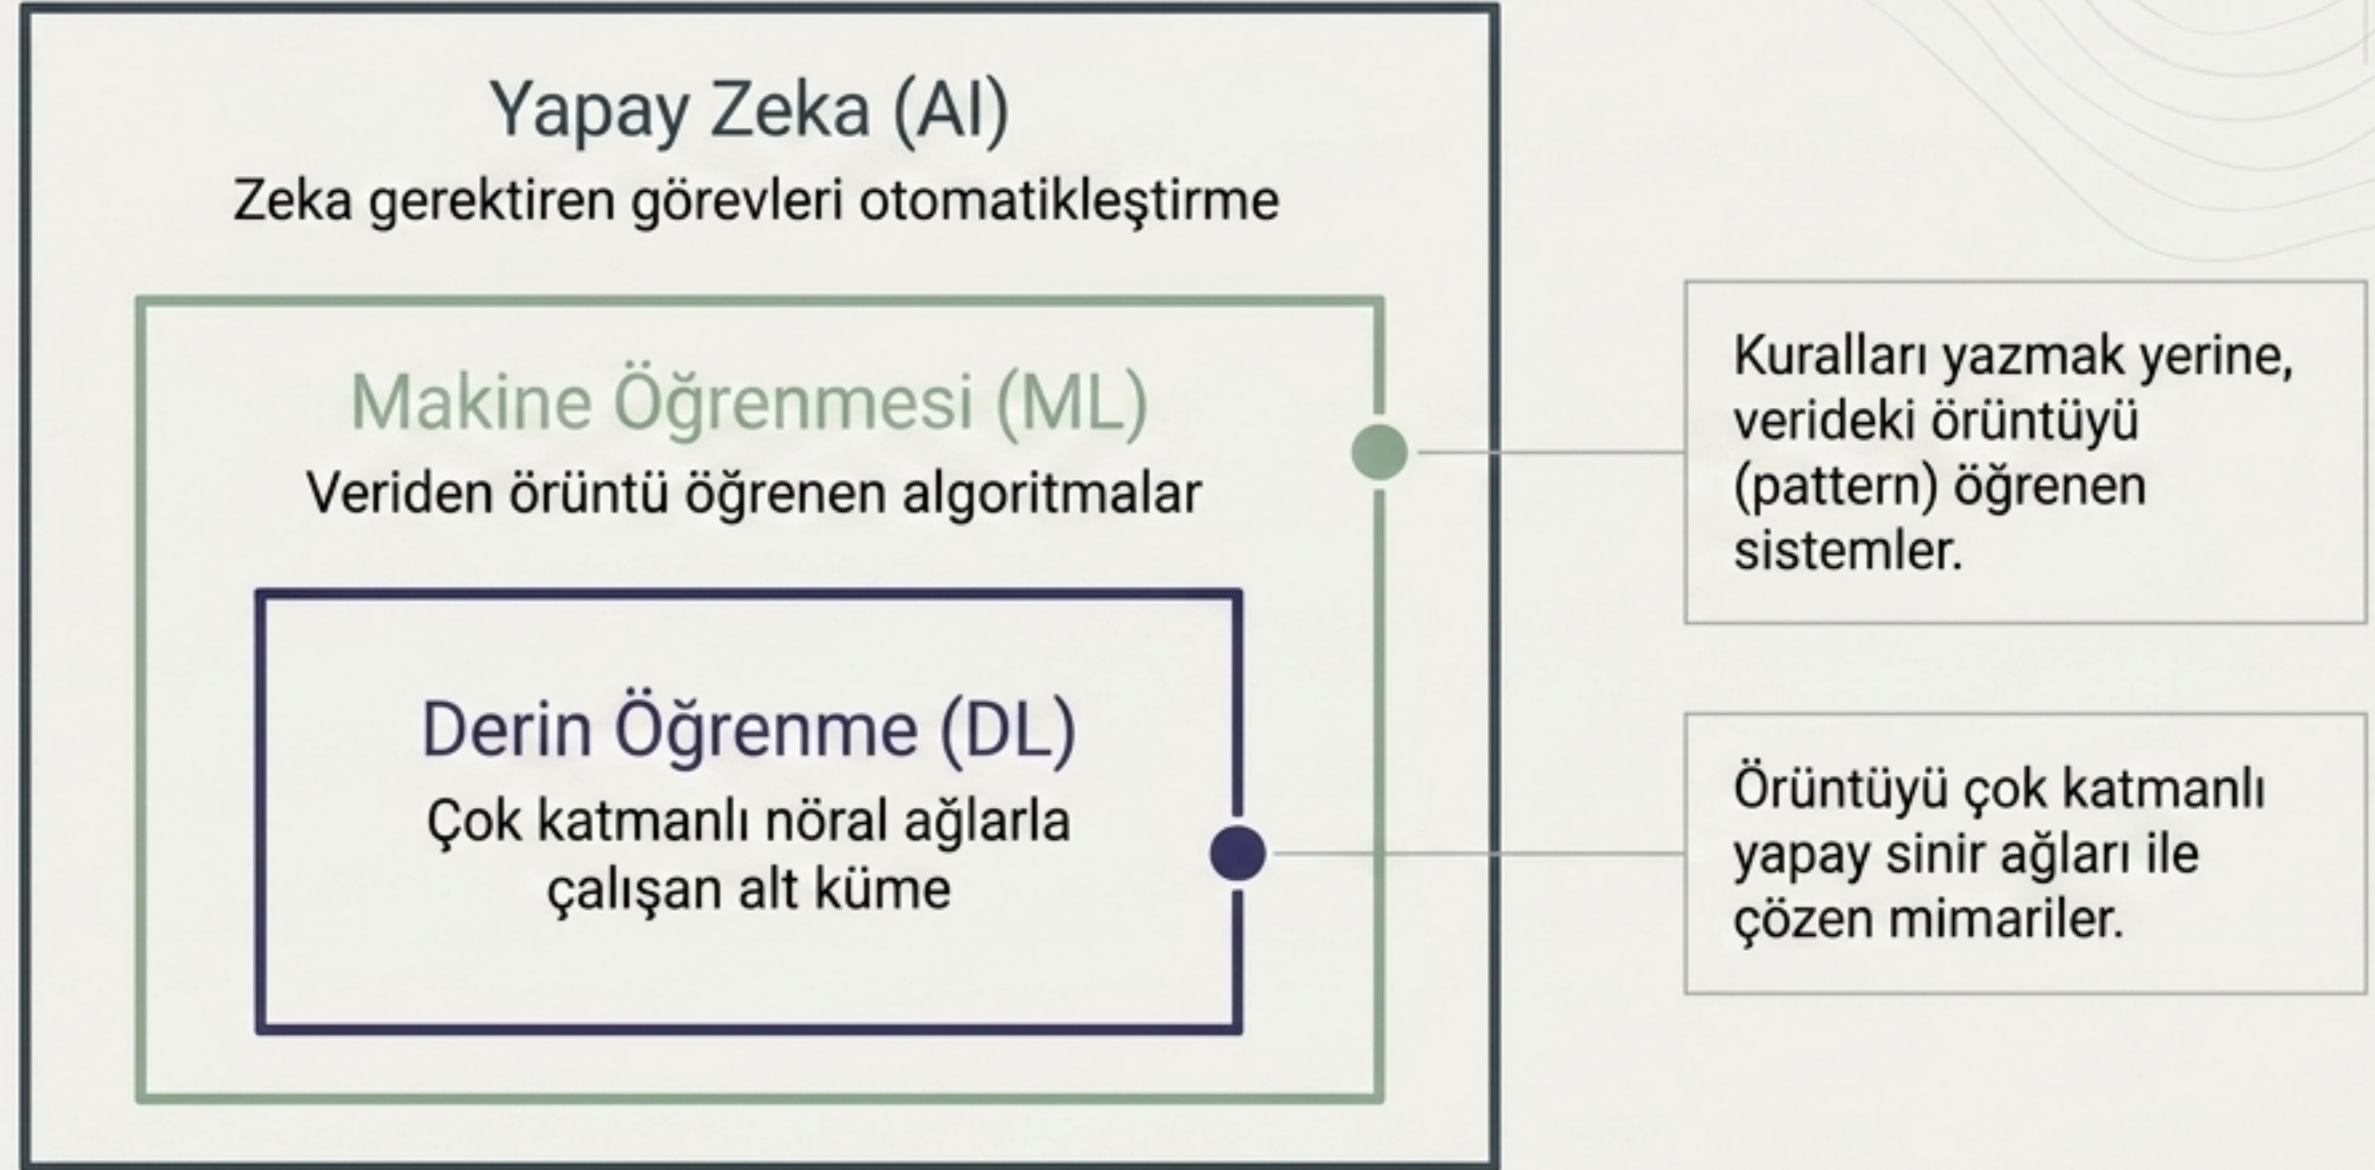



Makine Öğrenmesi ve Derin Öğrenme: Kavramsal Atlas

Zeka Gerektiren Görevleri Otomatikleştirmenin Mimari ve Matematiksel Temelleri (Başucu Rehberi)

Derin Öğrenme, Makine Öğrenmesinin; Makine Öğrenmesi ise Yapay Zekanın bir alt kümesidir.




Her öğrenme süreci verinin anatomisini anlamakla başlar: Özellikler (Features) ve Etiket (Label).








Gözetimli öğrenmede temel amaç, X'ten y'ye giden fonksiyonu çözmektir.



Makine öğrenmesi paradigmaları, verinin 'etiketli' olup olmamasına göre dört ana kadrana ayrılır.

Supervised (Gözetimli)	Semi-Supervised (Yarı Gözetimli)
 Tamamen etiketli veri. Regresyon (sürekli değer) ve Sınıflandırma (kategorik) yapar.	 Az etiketli + çok etiketsiz veri. Self-training (sahte etiketler) ve tutarlılık zorlaması kullanır.
Unsupervised (Gözetimsiz)	Self-Supervised (Kendi Kendine)
 Etiket yok. Model verinin kendi iç yapısını, örüntülerini ve benzerliklerini bulur.	 Veri kendi etiketini üretir. Model çözmesi için tasarlanan yapay bir görevi (pretext task) yaparken öğrenir.


Gözetimsiz öğrenme, gizli yapıları ortaya çıkarmak için dört temel strateji kullanır.

Clustering	Dim. Reduction	Anomaly Detection	Association Rule
 Benzer örnekleri gruplama.	 Yüksek boyutlu veriyi anlamlı küçültme.	 Normalden sapanı bulma.	 Apriori: "Bunu alan şunu da aldı" ilişkisi.
K-Means İşleyişi (Algoritma Döngüsü)		 Yakınsayana kadar tekrar et	
Rastgele k merkez noktası seçilir. 			

Kendi kendine gözetimli öğrenme, modelin 'yapay görevler' (pretext tasks) çözerek dünya temsillerini öğrenmesini sağlar.




Yapay Sinir Ağları (ANN): İnsan beyni nöronlarından ilham alan, veriyi işleyip anlamlı çıktı üreten çok katmanlı topolojilerdir.




Bir nöronun içyapısı: Girdilerin, ağırlıkların ve önyargının aktivasyon filtresinden geçtiği matematiksel bir dönüşüm tesisidir.

$$\text{output} = \text{activation}\left(\sum(\text{input}_i \times \text{weight}_i) + \text{bias}\right)$$




Öğrenme Döngüsü: Binlerce 'epoch' boyunca tekrarlanan bir tahmin, hata ölçümü ve düzeltme mekanizmasıdır.




Görüntü verisinde klasik ağların ‘kablo karmaşası’ yerine, CNN’ler uzamsal yapıyı koruyan kayan pencereler kullanır.

Klasik Fully-Connected Ağ



Devasa Kablo Karmaşası: Her piksel bir nörona tam bağlıdır. Aşırı fazla parametre gerektirir.

CNN Yaklaşımı - Convolution



Filtreleme (Sliding Window): Aynı filtre tüm görüntüde gezer. Özellikleri (kenar, köşe) tespit eden bir harita (Feature Map) çıkarır.


CNN Avantajları

Parameter sharing
(aynı filtre, az parametre)

Local connectivity
(küçük bölgeye odaklanma)

Translation invariance
(nesne yer değiştirse bile tanıma)

Tipik bir CNN Boru Hattı (*Pipeline*), görüntüyü aşama aşama soyutlayarak karara varır.



1. Girdi

2. Convolution

Layer: 3x3 Filtreler
nokta çarpımı yapar
(Feature map
üretilir).

3. Activation (ReLU):

$f(x) = \max(0, x)$
formülü ile doğrusal
olmayanlık katar.

4. Pooling (Max/Avg):

Boyutu küçültür,
hesaplama yükünü azaltır,
küçük konum
değişimlerine karşı
sağlamlık (robustness)
sağlar.

5. Flatten & Fully
Connected (FC):


Çıkarılan özellikler
klasik sinir ağına
bağlanır.

6. Softmax:

Çıktı olasılıkları
(Örn: 90% Kedi).

Bilgisayarlı Görü (Computer Vision) görevleri, istenen çıktının zorluk ve detay seviyesine göre üç evreye ayrılır.

Image Classification



Sadece varlık/sınıf bilgisi.
Konum yok.
"Bu görüntüde ne var?"
sorusunu yanıtlar.

Object Detection



"Neler var VE nerede?"

- İki Aşamalı (R-CNN vb.): Bölge önerisi + sınıflandırma (Daha kesin ama yavaş).
- Tek Aşamalı (YOLO, SSD): Tek geçişte konum + sınıf (Hızlı, gerçek zamanlı).

Segmentation



En detaylı seviye. **Semantic** (tüm insanlara aynı renk maske) ve **Instance** (her bireye ayrı maske, örn: Mask R-CNN).

Bir modelin başarısı, verideki asıl eğilimi ne kadar iyi yakaladığına ve gürültüyü ne kadar dışladığına bağlıdır.

Underfitting



Model çok basit. Pattern'i öğrenememiş. Train ve Test kaybı yüksek. (Sebebi: Az parametre, yetersiz özellik).

İyi fit




Model dengeli. Genel eğilimi yakalar, gürültüyü ezberlemez.

Overfitting



Model çok karmaşık. Gürültüyü ezberlemiş. Eğitimde muhteşem, yeni veride başarısız.

Overfitting'in Anatomisi: Eğitim kaybı (Train Loss) düşerken, doğrulama kaybının (Val Loss) artmaya başladığı o kritik kırılma noktası.



Sebeup: Model çok karmaşık, veri az veya gereğinden uzun süre eğitilmiş.

Büyük Resim: Makine Öğrenmesi ve Derin Öğrenme Mimarisi Sentezi (Kopya Kağıdı)

