

YOLO: Sadece Bir Kez Bakarsın

Nesne Tespiti Algoritmalarının Evrimi, Çalışma Mantığı ve Kaputun Altındaki Matematik.

Sude yaren çelik

Technical

Sınıflandırma



Resimde kedi var.

Technical

Nesne Tespiti



[cyan_box: cat]

Kedi burada.

Technical

Segmentasyon




[magenta_mask: cat]

Kedinin piksel sınırları şunlardır.

YOLO'nun odaklandığı alan Nesne Tespiti (Object Detection)'dir. Hem "Bu nedir?" (Sınıflandırma) hem de "Nerededir?" (Konumlandırma) sorularını aynı anda, milisaniyeler içinde cevaplaması gerekir.

İki Aşamalı Hantallık: Eski Yöntemler Neden Yavaştı?

Geleneksel '**Two-Stage Detector**' sistemleri bilgisayarın resmi körlemesine, binlerce küçük parçaya bölerek incelemesine dayanıyordu.




R-CNN	~2000 Region Proposal (Bölge Önerisi) oluşturur. Her birini ayrı CNN'e gönderir. Sonuç: Çok yavaş.
Fast R-CNN	CNN bir kez çalışır ama bölge önerileri Selective Search ile üretildiği için hâlâ yavaştır.
Faster R-CNN	Bölge önerilerini RPN (Region Proposal Network) üretir. Daha hızlıdır ama iki aşamalı mantık devam ettiği için gerçek zamanlı (real-time) uygulamalarda sınırlıdır.


Paradigma Değişimi: Tek Bir Regresyon Problemi

YOLO (You Only Look Once), resmin tamamını ağı tek seferde sokar. "Bölge önerme" (Region Proposal) aşamasını tamamen çöpe atar.

İki Aşamalı (Two-Stage)



Tek Geçiş (Single Pass)



Bütünsel Bakış Açısı

Model resmi binlerce küçük parçaya ayırmak yerine bütün olarak analiz ettiği için, nesnelerin arka planla ve birbirleriyle olan **ilişkilerini daha iyi anlar**. Bu sayede hata payı düşer ve hız geçek zamanlı (real-time) seviyelere çıkar.


YOLO Boru Hattı (Pipeline): Görüntüden Tahmine



Algının Merkezi: S x S Grid Dinamikleri


Eğer bir nesnenin merkez noktası hangi grid hücresinin içine düşüyorsa, o nesneyi tespit etmekten SADECE o hücre sorumludur.

Resim CNN katmanlarından geçip küçülerek bir 7x7 matrise dönüştüğünde, her bir hücre kendi alanında bir nesne olup olmadığını, varsa genişliğini, yüksekliğini ve sınıfını bulmakla görevlendirilir.



Örnek YOLO algoritması çıktısı (3)

Bir Hücrenin Anatomisi: Tahmin Vektörü



Koordinatlar (Bounding Boxes)

B_x , B_y : Nesnenin merkezinin, o hücrenin sınırlarına göre konumu.

B_w , B_h : Kutunun tüm resme göre toplam genişliği ve yüksekliği.

Güven Skoru (Confidence Score)

Modelin kutuyu ne kadar doğru çizdiğine ve içinde nesne olduğuna duyduğu inanç (0 ile 1 arası).


Sınıf Olasılığı (Class Probabilities)

Nesne bulunduysa, bunun hangi sınıfa (insan, kask, araba vb.) ait olduğu.

Matematiksel Örtüşme: IoU (Intersection over Union)


$$\text{Güven Skoru} = P(\text{Nesne}) \times \text{IoU}$$

YOLO'nun nihai kutu başarısı, sadece içindeki nesne olasılığına $P(\text{Nesne})$ değil, aynı zamanda kutunun gerçek nesne sınırlarıyla (Ground Truth) ne kadar kusursuz örtüştüğüne (IoU) bağlıdır.




Kötü Örtüşme (Poor)

Alanların kesişimi zayıf.



İyi Örtüşme (Good)

Kutular büyük oranda çakışıyor.




Mükemmel Örtüşme (Excellent)

Kesişim alanı, toplam alana (Union) neredeyse eşit. ($\text{IoU} \approx 1$).

Gürültüyü Temizlemek: Non-Maximum Suppression (NMS)



Tek bir nesne için yan yana duran gridler yüzlerce gereksiz kutu üretebilir.



NMS İŞLEM ADIMLARI (NMS PROCESS STEPS)

1. Güven skoru belirli bir seviyenin (örn. 0.5) altında olan tüm kutuları çöpe at.
2. Kalanlar arasından en yüksek skorlu kutuyu seç (Kutu A) ve ana çıktı olarak belirle.
3. Kutu A ile %50'den fazla örtüşen ($IoU > 0.5$) diğer tüm rakip kutuları sil. Sonuç: Nesne başına tek bir net kutu.

YOLO MODELLERİN KARŞILAŞTIRILMASI



her çizgi üzerindeki noktalar ise o modelin nano (n), small (s), medium (m), large (l) ve extra-large (x) sürümlerini temsil eder


LATENCY: modelin bir resmi işlemesi için geçen milisaniye , sola ne kadar yakınsa o kadar hızlıdır.

COCO mAP (%): modelin doğruluğunu gösterir , yukarı çıktıkça model başarılıdır.

FLOPS: bilgisayarın bir resmi işlerken ne kadar işlem yaptığıdır.(bilgisayarı ne kadar yorduğu-Donanım Yüğü)

Mimari Evrim: Anchor Box'tan Anchor-Free'ye Geçiř

YOLOv2 ile Gelen Çözüm (Anchor Box)




YOLOv1'de aynı grid hücreesine düşen birden fazla nesneyi tespit etmek zordu. YOLOv2 ile her grid hücresi birden fazla Anchor Box kullanarak tahmin yapar.

Model, aynı grid içindeki farklı nesneleri bulabilmek için önceden tanımlanmış referans kutular kullanır. Model bu kutuları nesneye göre büker.

(Dezavantajı: Kutu boyutlarını önceden ayarlamak karmaşıktır).

Modern Yaklaşım (Anchor-Free)



YOLOv8 ve sonrasında önceden çizilmiş kutular terk edildi. Model artık doğrudan nesnenin merkez noktasını ve bu merkeze göre sınır değerlerini tahmin eder. Daha esnek ve eğitilmesi çok daha kolaydır.


Karar Matrisi: Hız, Doğruluk ve Donanım Ödünleşimi

Her YOLO sürümü, donanım kapasitesine göre ölçeklenen farklı boyut varyantlarına sahiptir. Hedef, **en düşük hesaplama maliyeti (FLOPS)** ile en yüksek doğruluğa ulaşmaktır.

Floating Point
Operations Per Second

Boyut Rehberi

1	n (Nano) & s (Small)	Raspberry Pi, Mobil Telefonlar. Çok hızlı (düşük gecikme), hafif projeler.
2	m (Medium)	Genel Kullanım. Hız ve doğruluk arasında altın oran.
3	l (Large) & x (Extra-Large)	GPU bulunan sunucular. En yüksek mAP doğruluğu, karmaşık endüstriyel görevler.




YOLO Sürüm Geçmişi ve Özellik Matrisi

2016 YOLOv1 Joseph Redmon	İlk gerçek zamanlı nesne tespit modeli (Sadece Bir Kez Bakarsın felsefesi). (Redmon)
2020 YOLOv5	PyTorch tabanlı yapıya geçiş. Farklı model boyutları (n,s,m,l,x) ve aşırı kolaylaşan eğitim süreci. (Ultralytics)
2023 YOLOv8	Anchor-Free mimarisi standartlaştı. Tespit, Segmentasyon ve Poz tahmini tek bir çatı altında birleşti. Popüler genel amaçlı model. (Ultralytics)
2024 YOLOv10	NMS algoritmasını tamamen ortadan kaldıran (End-to-End) yapı ile daha düşük gecikme. (Tsinghua Univ.)
2026 YOLO26	Yeni nesil gerçek zamanlı görüntü işleme, geliştirilmiş doğruluk-hız dengesi ve güncellenmiş eğitim altyapısı. (Ultralytics)

Deneyisel Sonuçlar ve Model Karşılaştırmaları (100 Epoch)


Modelin çizdiği kutu ile gerçek kutunun örtüşme oranı		Modelin çizdiği kutu ile gerçek kutunun örtüşme oranı		Modelin çizdiği kutu ile gerçek kutunun örtüşme oranı	
Kesinlik(Precision)	Duyarlılık(Recall)	mAP50(Genel Başarı)	mAP50-95(Konum Başarısı)	Toplam Süre(Saniye)	
%89.90	%80.51	%86.64	%52.07	2484 sn (~41 dk)	
%89.27	%81.17	%86.04	%52.25	3441 sn (~57 dk)	
%87.52	%77.69	%84.58	%51.84	3422 sn (~57 dk)	

yolov8




değerin yüksek olması, modelin sadece nesneyi bulmakla kalmayıp, etrafına çizdiği kutunun milimetrik olarak ne kadar kusursuz oturduğunu gösterir.

yolov26



yolov11



KAYNAKLAR

- (medium yiğit mesci)
- selcan atak
- ECE AKDAĞLI