


TOKENİZASYON YÖNTEMLERİ




TOKENİZASYON YÖNTEMLERİ (BPE-WORDPIECE-UNIGRAM)

Hazırlayan: Yasemin KUŞ


Tokenizasyon: LLM'lerin Yapı Taşlarını Blok Blok İnşa Etmek

Büyük Dil Modellerinin dili nasıl gördüğüne dair eksiksiz bir rehber —
BPE, WordPiece ve Unigram mimarilerinin anatomisi.

Geliştiriciler ve Yapay Zeka Mühendisleri için Görsel Referans



Bir Tokenizer'ın Mimarisi: Hugging Face Boru Hattı




Adım 1 & 2: Hazırlık Aşaması (Metni Makineye Uygun Hale Getirmek)



Panel 1: Normalizer (Temizlik)


Metni standartlaştırır. (NFD, Lowercase, StripAccents)



NFD (Canonical Decomposition), aksanlı karakterleri (é) temel karakter (e) ve aksan birimi olarak ikiye ayırır. Sonra StripAccents aksanı atar.


Panel 2: Pre-Tokenizer (Kaba Kesim)

Metni modelin inceleyeceği 'kelimeciklere' (word boundaries) böler.




```
[("Hello", (0, 5)), (" ", (5, 6)),  
("world", (7, 12)), ("!", (12, 13))]
```


Adım 3: Model - Tokenizasyonun Kalbi



Ön-tokenizasyon sonrası elimizde kelimeler var. Ancak model bu kelimeleri olduğu gibi alamaz, nadir kelimeleri (örn: unhug) anlamlı parçalara (örn: un + hug) bölerek 'Bilinmeyen Kelime' ([UNK]) problemini çözmek için onları alt-kelimelere (subwords) bölmek zorundadır.



BPE (Byte-Pair Encoding): Frekansa Dayalı Birleştirme




Eğitim (Training) - Aşağıdan-Yukarı (Bottom-Up)




Uygulama (Tokenization)

Kelimeler karakterlere bölünür, ardından öğrenilen kurallar sırasıyla uygulanır.



WordPiece: BERT'in Skora Dayalı Motoru



Matematiksel Filtre


Algoritma Tipi: Aşağıdan-Yukarı (Bottom-Up).
Ancak salt frekans yerine formül kullanır.

$$\text{Skor} = \frac{\text{freq_pair}}{(\text{freq_A} * \text{freq_B})}$$

Neden? (un, ##able) çok sık geçse bile, un ve ##able tek başlarına da çok sık geçtiği için skorları düşük olur. Buna karşın nadir kelime parçaları (hu, ##gging) yüksek skor alıp öncelikli birleşir.

Özel Ön Ek:


Kelimenin başlangıcında olmayan, içinde (devamında) olan parçaları işaretler.



Tokenizasyon Yaklaşımı: Kelimenin başından başlayarak sözlükteki en uzun eşleşmeyi bulma mantığı. Eğer parça sözlükte yoksa kelime tamamen [UNK] olur.

Eğitim (Budama - Pruning)


Algoritma Tipi: Yukarıdan-Aşağı (Top-Down).
BPE'nin tam tersidir.



Sözlükteki her bir parça için olasılık hesaplanır. Her bir token silinirse derlem üzerindeki ‘Kayıp’ (Loss) ne kadar artar hesaplanır. Kaybı en az etkileyenler (en gereksizler) silinir (pruned).

Uygulama (Viterbi Yolu)

Kelimeler olasılık hesaplamasıyla bölünür.
 $P(['un', 'hug'])$ ile $P(['u', 'n', 'hug'])$ karşılaştırılır.



Kelimeler olasılık hesaplamasıyla bölünür.
 $P(['un', 'hug'])$ ile $P(['u', 'n', 'hug'])$ çarpılarak karşılaştırılır. En yüksek olasılıklı rota seçilir.




Çekirdek Algoritmalar: Karşılaştırma Matrisi (Cheat Sheet)




Özellik	BPE (Byte-Pair Encoding)	WordPiece	Unigram
Temel Yaklaşım	Aşağıdan Yukarı (Bottom-Up)	Aşağıdan Yukarı (Bottom-Up)	Yukarıdan Aşağı (Top-Down)
Eğitim Kriteri	En Yüksek Frekans (Sıklık)	Skor ($\text{freq_pair} / (\text{freq_A} * \text{freq_B})$)	Kayıp Optimizasyonu (Budama)
Bölme Stratejisi	Öğrenilen kuralları sırayla uygula	Sözlükteki en uzun ön-eki ara	En yüksek olasılıklı Viterbi yolu
Özel Karakter	Genellikle Yok (GPT-2'de Ġ boşluk)	İç/Devam kelimelerde ## ön-eki	Genellikle _ veya  (SentencePiece)
Bilinmeyen Karakter (OOV)	Byte-level BPE'de [UNK] imkansızdır	Kelimenin tamamı [UNK] olur	Asla silinmeyen temel karakterlere döner
Temsilci Modeller	GPT-2, GPT-3, GPT-4, Llama 2	BERT, DistilBERT, Electra	T5, XLNet, ALBERT



Adım 4: Ardıl İşlem (Post-Processing) ve Şablonlama



Tokenizasyon bittikten sonra, modelin eğitim mimarisine uygun olarak cümlelerin başına ve sonuna özel kontrol tokenleri eklenir. Özel tokenler, modele metnin bittiğini, yeni bir dökümanın veya yeni bir cümleinin başladığını haber verir. Modellerin asistan gibi davranması (Fine-tuning) için bu işaretçiler hayatidir.



GPT modellerindeki `<|endoftext|>` tokeni, doküman sınırlarını (delimiter) belirtir.

Özet: Dil Modelleri Dünyayı Kelimelerle Değil, Tokenlarla Anlar

Hap Bilgi 1

Modellerin Anatomisi

Tokenizer'lar LLM'lerden tamamen bağımsız çalışır. Kendi eğitim verileri, kendi sözlükleri ve kendi kuralları vardır.



Hap Bilgi 2

Modüler Yapı (Hugging Face)


Her tokenizer 4 temel aşamadan oluşur (Normalleştirme, Ön-belirteçleme, Model, Ardıl İşlem). Algoritma (BPE/WP/Unigram) sadece 3. aşamadır.



Hap Bilgi 3

Felsefi Ayrım

- **BPE**: Sıklığa göre birleştirir.
- **WordPiece**: Skora göre birleştirir.
- **Unigram**: Olasılığa göre buda.



Hap Bilgi 4

Performansın Gizli Anahtarı

LLM'inizin matematikte kötü olması veya Türkçe'de pahalı cevaplar vermesi modelin kendisiyle değil, tokenizer'ın o dili nasıl parçaladığı ile ilgilidir. Optimizasyon burada başlar.



Tokenizasyon, doğal dil ile vektör uzayı arasındaki en kritik köprüdür.

Kaynakça

Hugging Face LLM Course: Building a tokenizer, block by block

Hugging Face Tokenizers Documentation

Andrej Karpathy: Let's build the GPT Tokenizer (YouTube)

Christopher GS: The Technical User's Introduction to LLM Tokenization (Blog)

Oğuzhan Yenen: Unigram Tokenizasyon Algoritması (Medium)